证明陪练场

面向数学分析证明教学的分步引导系统

技术方案与实验设计

（版本 2.0）

编　　制　　项目组（@JonathanLye）

文档编号　　MY-PROOF-2026-001

版　　本　　v2.0

日　　期　　2026 年 10 月 27 日

状　　态　　供评审 · 第 2 稿

本稿用于课题组内部评审与授课教师确认，不对外发布。文中估算值均标注口径，未经独立复核的数据已注明来源性质。

摘　要

本文报告一套面向数学分析课程证明写作训练的生成式人工智能系统及其课堂实验方案。系统的做法是把“给答案”换成“指出下一步”：学生分步书写证明并逐步提交，系统对照教师审核过的题目包定位第一处可疑步骤，以提问的方式返回；学生卡住时按 L1 至 L4 四级提示阶梯逐级获取帮助，L1、L2 为预写文本，L3、L4 由大模型生成，并受提示预算与两层防泄题闸门的约束。系统不判定证明是否正确，只承担首错定位与分级提示两项工作。为支撑教改论文，系统把每次交互写入只追加的事件表，看板、导出与统计共用同一数据源；实验采用前后测加平行卷交叉平衡的对照设计，并给出统计功效与最小可检测效应的复算结果。按双侧 α=0.05、两组各 30 人计算，检出 8 分差（d=0.32–0.53）的功效仅 0.24–0.54；达到 0.80 需每组 60 人，或改用交叉设计。本文同时给出部署、成本、进度与合规安排，以及需要团队与授课教师确认的决策事项。

关键词：数学分析；证明教学；生成式人工智能；提示阶梯；防泄题；对照实验；学习分析

Abstract

We describe a generative-AI system for proof-writing practice in mathematical analysis and a classroom study designed to evaluate it. Instead of producing answers, the system locates the first questionable step against instructor-reviewed problem packages and returns a question; when students are stuck, help is released through a four-level hint ladder, with L1/L2 pre-written and L3/L4 generated under a hint budget and a two-layer leakage gate. The system never judges proof correctness. Every interaction is appended to an event log that feeds the teacher dashboard, data exports and statistical analysis alike. A pre/post design with counterbalanced parallel forms is specified, and statistical power is recomputed: with 30 students per arm, power to detect an 8-point difference (d = 0.32–0.53) is 0.24–0.54; 60 per arm or a crossover design is required to reach 0.80. Deployment, cost, schedule and compliance arrangements are also reported.

Keywords: mathematical analysis; proof instruction; generative AI; hint ladder; leakage prevention; controlled experiment; learning analytics

目　录

摘要.....II
Abstract.....II
1　引言.....1
1.1　问题与背景.....1
1.2　设计目标.....1
1.3　主要工作.....1
2　研究定位与设计约束.....2
2.1　作为实验平台的定位.....2
2.2　四条硬约束.....2
2.3　差异化来源.....2
3　相关工作.....3
3.1　自动反馈与证明评估.....3
3.2　提示与支架.....3
3.3　本方案的位置.....3
4　系统设计.....3
4.1　总体架构.....3
4.2　学生作答循环.....4
4.3　诊断：定位第一处可疑步骤.....5
4.4　提示阶梯与防泄题闸门.....5
4.5　数据与日志.....6
5　实验设计.....7
5.1　题库与干预剂量.....7
5.2　分组、平行卷与对照.....8
5.3　两种设计及其取舍.....8
5.4　统计功效与样本量.....9
5.5　分析计划与评分信度.....10
6　实现与运营.....10
6.1　技术选型.....10
6.2　部署、可用性与合规.....11
6.3　成本.....11
6.4　进度与里程碑.....12
7　风险与合规.....13
7.1　风险矩阵.....13
7.2　合规要点.....14
8　结论与下一步.....15
参考文献.....16
附录 A　题目包与诊断输出.....18
附录 B　数据表与导出字段.....18
附录 C　成本明细.....19
附录 D　待决策事项.....19
附录 E　参考开源项目与许可.....19

1 引言

1.1 问题与背景

数学分析课程的核心训练是证明写作。学生常见的困难并不是看不懂参考证明，而是无法把“看懂”转成“写出”：不知道下一步该调用哪个定义或定理，也无法判断自己写下的那一步是否成立。传统作业的反馈周期以天计，一对一答疑受师资与课时限制，很难在写作过程中介入。

生成式模型提供了即时反馈的可能，但直接给答案会削弱学习。Bastani 等在高中数学的现场实验中发现，无护栏的通用助手使练习阶段成绩提高 48%，撤除后考试反而下降 17%；带护栏的导师型助手使练习提高 127%，考试成绩与对照持平[1]。这一结果说明，问题不在模型能力，而在帮助的释放方式。Kestin 等在哈佛物理课的交叉设计随机试验中报告，按教学设计约束的 AI 导师组后测中位数高于主动学习对照组[2]；该实验的对象是物理概念，不是证明写作，但它支持“约束得当的 AI 反馈可以优于常规课堂”这一前提。

另一条约束来自评测侧。QEDBench 在 272 道大学水平证明题上比较 7 个评审模型与人工评分，发现评审模型存在系统性正向偏差，平均分虚高 0.18 至 0.36；Llama 4 Maverick 的通过率为 90.2%，人工基线为 67.7%[3]。Srivatsa 等在数学应用题的分步解答上进一步发现，即使把参考答案交给模型，定位第一处错误仍然困难[4]。两项结果共同支持一个保守的设计判断：模型可以辅助定位与提示，不宜承担正确性判定。

1.2 设计目标

本项目服务于一项教改论文，目标不是做消费级产品，而是提供一个可解释、可复现、可统计的实验平台。论文要回答的问题是：分步引导的人工智能是否比直接给答案更能帮助学生写出证明。围绕这一问题，系统需要满足三类要求：干预在实验期内保持一致；每个动作留下可分析的记录；测试与练习严格隔离，系统不能退化为答案机。这三类要求把技术选择限定得很窄，也决定了首版的功能边界。

1.3 主要工作

本文的工作包括四项。第一，设计以题目包为核心的诊断流程：模型对照教师审核过的关键步骤与常见错误，只输出第一处可疑步骤与一句提问，不判定正确性。第二，设计四级提示阶梯与两层防泄题闸门：L1、L2 使用预写文本，L3、L4 由模型生成，并以关键步骤计数、输出长度、文本重合度与异厂商复核共同约束。第三，设计以只追加事件表为中心的数据结构，使教师看板、研究导出与论文统计共用同一数据源。第四，给出实验设计与统计功效的复算，说明 30 对 30 的组间设计在真实课堂中检出 8 分差的把握不足，并给出可行的替代方案。

2　研究定位与设计约束

2.1　作为实验平台的定位

授课教师已确认目标是发表教改论文，因此系统的第一属性是实验平台。消费级产品追求留存与满意度，实验平台追求可比较的因果证据：同一份题库、同一套提示规则、同一段实验窗口，两组学生只在“是否有分步引导”上不同。这一定位带来一个反直觉的取舍：功能越少，结论越干净。首版因此不开放拍照问答、不做错题本、不做作业布置，也不提供 AI 自动给分。开放式拍照问答看似方便，但它同时改变了题目范围、输入方式与提示规则，会成为无法控制的混淆变量。

2.2　四条硬约束

把论文目标翻译成工程约束，可以得到四条不可让渡的规则（表 1）。

干预稳定一致。实验期（12 月 1 日至 12 月 27 日）冻结提示词、模型版本与提示规则；模型快照号与提示词版本写入每条事件记录。若中途升级模型，组内差异会与模型差异混在一起，前后测比较失去意义。

数据完整可追溯。每个动作一行事件，只追加、不修改；导出字段齐全率不低于 98%，并作为内测门槛。事件表是唯一事实源，看板与导出都在其上演算，这样“与后台数据一致”是结构上的保证，而非人工核对的结果。

测试与练习隔离。前测、后测与延迟后测题目按 role 字段屏蔽，测试窗口内关闭诊断与提示，限时 30 分钟，提交后只记录不反馈。测试期间一旦出现提示事件，该次测量即作废。

不能变成答案机。实验组一旦能稳定拿到完整证明，干预就不再是“引导”，论文结论不成立。这是首版不做开放拍照问答的直接原因，也是提示预算与复核层存在的理由。

表 1　四条硬约束、技术对策与验收判据

约束	技术对策	验收判据
干预稳定一致	冻结提示词、模型快照与提示规则；版本号写入每条事件	实验期事件中 model 与 prompt_version 齐全率 100%
数据完整可追溯	只追加事件表，应用层禁止更新与删除	导出字段齐全率 ⩾ 98%；事件计数与导出行数一致
测试与练习隔离	测试模式关闭诊断与提示；测试题按 role 字段屏蔽	测试窗口内提示事件数为 0
不能变成答案机	提示预算、关键步计数、异厂商复核三层约束	多轮套话回归集泄题 0 条

2.3　差异化来源

与豆包爱学一类产品相比，本系统的差异不在模型，而在两处可控资产：一是 50 个由教师审核的题目包，包含参考证明、关键步骤、预写提示与常见错误；二是细粒度的过程数据，可以区分“独立完成”与“在提示下完成”。前者决定干预内容的质量，后者决定论文能回答的问题。模型可以替换，这两项资产不能。

3 相关工作

3.1 自动反馈与证明评估

面向数学的自动反馈研究大致分两条路线。一条以解题步骤为单位做验证与补救：Daheim 等构建了 1002 条由教师标注首错的分步推理链，把“先验证、再生成”拆成两步，明显降低了幻觉并提高了反馈的针对性[5]；Gohr 等在本科证明场景中部署了反馈系统，并说明预计算评分方案可以让教师在部署前审计系统行为[6,7]。另一条路线关注评测本身：QEDBench 显示评审模型对证明打分存在系统性正向偏差[3]，Srivatsa 等显示即使提供参考答案，定位首错仍然困难[4]，Zheng 等与 Panickssery 等则分别报告了 LLM 评审的位置偏差、冗长偏差与自我偏好[8,9]。CodeHelp 在编程课堂中以禁用关键词集合与教师视图约束模型行为，说明护栏与教师监督在真实课堂中可行[10]。这些结果指向同一个工程结论：把“判定”从系统中拿掉，只保留“定位”与“提示”。

3.2 提示与支架

教育技术领域对“给多少帮助”有长期讨论。Koedinger 与 Aleven 把这一矛盾概括为 assistance dilemma：帮助过多会削弱学习，帮助过少会导致挫败与放弃[11]。Aleven 等进一步指出，学生普遍不善于使用帮助功能，有效求助与学习收益正相关，但求助行为需要设计引导[12]。Hattie 与 Timperley 把反馈分为任务、过程、自我调节与自我四个层级，为“分级提示”提供了理论映射[13]。在证明教学上，Poulsen 等的 Proof Blocks 用拖拽步骤与依赖图判分，验证了步骤级支架在入门题型上的可行性[14]；Li 等的 ScaffoldLM 把教学计划与步骤级进度结合起来，避免提前泄露后续步骤[15]。这些工作构成本方案提示阶梯与题目包结构的直接来源。

3.3 本方案的位置

与上述工作相比，本方案不追求更强的证明能力，而是在真实课程约束下组合已有机制：以教师审核的题目包替代在线生成的参考解，以四级提示阶梯替代单轮反馈，以两层闸门替代单条提示词，以只追加事件表替代分散日志。Mahinpei 等发现，在证明课程中模型与助教的评分判断存在实质分歧，但模型反馈对存在重大错误的作业仍有价值[16]；这与本文“只标可疑、不判分”的边界一致。据检索所见，把上述机制同时用于一项可发表对照实验的实现报告仍不多见，本文的价值主要在工程与实验设计层面。

4 系统设计

4.1 总体架构

全部请求进入同一个 Next.js 应用，页面与 API 在同一仓库；模型密钥只保存在服务端，前端不接触模型原始输出，只接收通过闸门的那一句。部署为单机 Docker Compose：Caddy 负责 HTTPS 与反向代理，Next.js 以 standalone 镜像运行，PostgreSQL 16 存放业务数据与事件，对象存储保存每日备份（图 1）。

架构上有三个刻意选择。其一，不用 Electron：确认书要求手机与平板可用，桌面应用无法满足。其二，不引入 Python 服务：SymPy 能验算，但验证不了自由书写的证明，首版用不上。其三，第三方服务集中在两个模型接口，且复核模型来自另一家厂商，用于规避自我偏好偏差[9]。

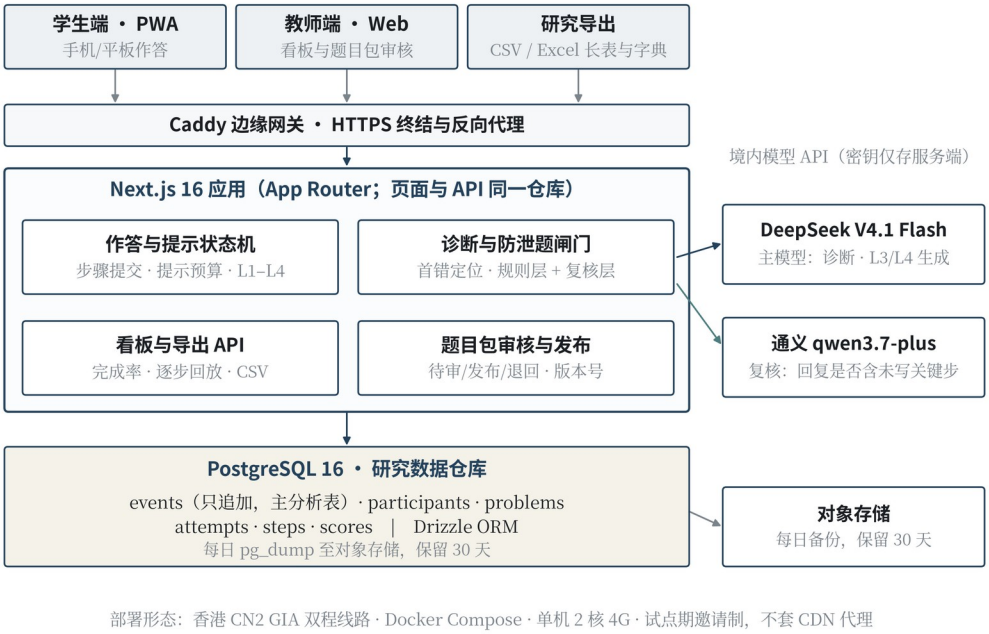


图 1　系统总体架构（容器级）

注：实线为同步请求，虚线为异步事件写入与备份；灰色框为第三方服务。模型密钥仅驻留服务端，前端只接收通过闸门的单句提示。

4.2　学生作答循环

一次作答同时产出三样东西：学生的练习、教师看板上的一个点、导出表里的一行。流程为：用教师发放的随机账号码登录（不输入姓名与学号），选题（本周必做 3 题置顶），可选写一句思路，分步书写证明并逐步提交；系统对照题目包诊断，只标出第一处可疑，以提问返回；学生改写后再次提交，或按需请求提示；完成后看到 3–5 句总结（图 2）。

测试模式与练习模式共用同一作答界面，但关闭诊断与提示、限时 30 分钟、提交后只记录不反馈。界面一致可以降低测量误差：学生面对的是熟悉的输入方式，差异只来自是否获得引导。

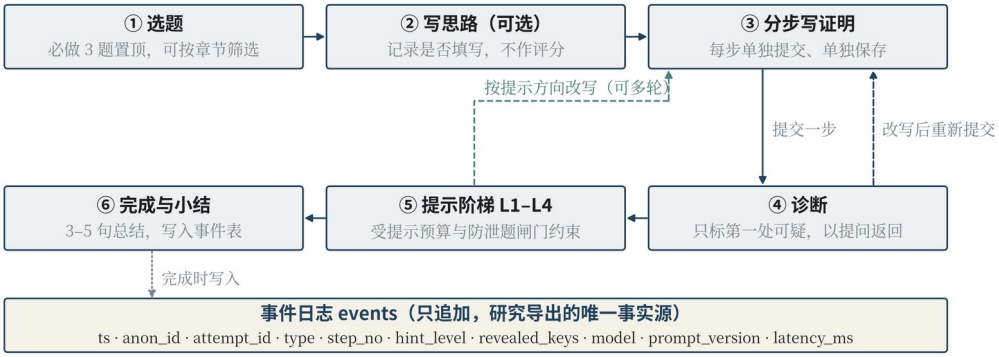


图 2　一次作答的核心循环与事件写入

注：④→③ 为同一题内的改写循环；⑤→③ 为按提示改写路径，虚线表示可重复；所有交互写入只追加的 events 表。

4.3　诊断：定位第一处可疑步骤

4.3.1　题目包

题目包是诊断的依据，每题一份，由 AI 起草、教师审核，包含题面、1–2 种参考证明、关键步骤 K1–Kn 及依赖关系、每个关键步骤预写的 L1/L2 提示、常见错误类型与识别特征、以及允许使用的定理集合（字段见附录 A 表 A1）。把参考证明拆成带依赖的关键步骤，是让模型“定位”而非“评判”的前提：模型只需判断学生已写步骤与关键步骤的匹配情况，不需要给出对错结论。

4.3.2　结构化输出

诊断调用的输入是题目包与学生已提交的步骤，输出为结构化 JSON，包含 suspect_step、error_type（取自题目包的常见错误枚举）、question_to_student 与 matched_key_steps（字段见附录 A 表 A2）。前端只渲染两样东西：可疑步骤的标记，以及那一句提问。这样做的代价是诊断的表达能力受限，收益是行为可预测、可回归测试：每次修改提示词，都可以用固定测试集检验定位是否漂移。

需要说明适用边界。QEDBench 与 Srivatsa 等的结果都表明，模型在“定位错误”上的可靠性低于“生成解释”[3,4]；后者使用的数据是数学应用题而非自由书写的证明，把结论外推到证明写作需要谨慎。因此本系统把诊断定位为提示信号而非评分依据，前测与后测的分数始终由教师按评分细则给出。

4.4　提示阶梯与防泄题闸门

提示分四级（图 3）。L1 复述题意与相关定义，L2 指向下一步可用的定义或定理，两级均取自题目包预写文本，不调用模型，泄题风险为零。L3 指出缺失关键步骤的方向，L4 给出该步骤的骨架，两级由模型生成，须通过闸门后才返回前端。预算为：L1、L2 不限次数，L3 每题至多 2 次，L4 每题至多 1 次；同一题累计透露的关键步骤不超过 2 个，达到上限后停止升级，改为建议回看定义或询问教师。

闸门分两层。规则层做四件事：统计已透露的关键步骤数，限制输出长度（不超过 120 字、公式不超过 2 行），检测与参考证明的文本重合度（连续 12 字以上重合即拦截），并要求输出落在“方向”或“骨架”的模板内。复核层由另一家厂商的模型判断“这条回复是否包含学生尚未写出的关键步骤”，复核失败或超时一律拦截，回退到预写的 L1/L2。这里的 fail-closed 是刻意设计：漏放一条泄题回复的代价，高于多给一次提示。

回归测试用 promptfoo 建立，覆盖四类场景：单轮套话（直接要答案、冒充教师、“只想核对一下”）、多轮渐进套话（连续要 L4、改写题面重问）、正确证明不被误报、错误证明被标出。每次修改提示词即运行全套测试，上线门槛是泄题 0 条。

这一设计有明确的理论对应：L1 至 L4 大致对应 Hattie 与 Timperley 所划分的任务、过程与自我调节层级[13]；提示预算对应 assistance dilemma 中“按需释放”的一侧[11]；复核层换用异厂商模型，针对的是自我偏好偏差[9]。

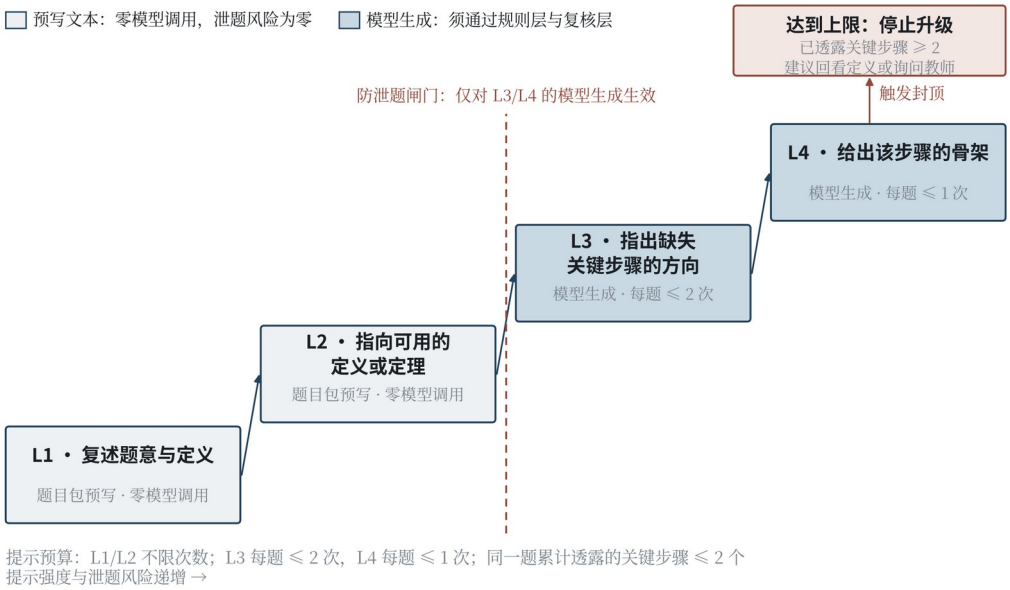


图 3　提示阶梯与防泄题闸门

注：L1、L2 取自题目包预写文本；L3、L4 由模型生成，须通过规则层与复核层。同一题累计透露关键步骤达到 2 个即封顶。

4.5　数据与日志

所有统计都从一张只追加的 events 表算出来。表结构包含 ts、anon_id、attempt_id、type、step_no、hint_level、revealed_keys、model、prompt_version、latency_ms 等字段；participants、problems、attempts、steps、scores 五张表提供上下文（字段见附录 B 表 B1）。events 不允许 UPDATE 与 DELETE，应用层只做插入；派生指标在看板、导出与论文统计中共享同一套口径（图 4、附录 B 表 B2）。

匿名化在入口处完成：教师发放随机账号码，“账号码—学号”对照表只保存在教师本地电脑，服务器不存姓名与学号，实名的成绩合并也在本地完成。这一设计把合规风险压到最低，代价是丢失了与教务数据的自动关联，需要教师在本地完成一次人工映射。

前端草稿实时写入浏览器 IndexedDB，联网后同步；离线产生的事件带客户端时间戳补传，以 event_uuid 去重。考虑到校园网在晚高峰的不稳定，这一层不是可选项。

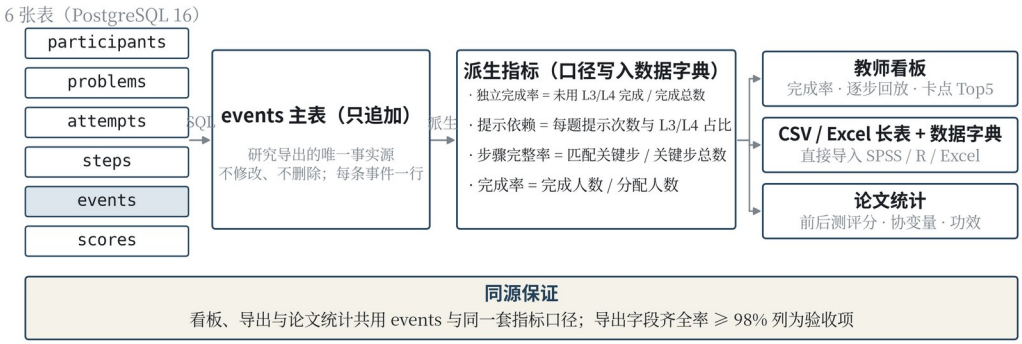


图 4　从事件表到指标与导出的数据流水

注：看板、导出与论文统计共用 events 与同一套口径；派生指标定义见附录 B 表 B2。

5　实验设计

5.1　题库与干预剂量

50 道题是题库容量，不是每人的练习量。确认书规定的节奏是每周 3 题、连续 4 周，共 12 道，这是论文中的干预剂量。题库按用途切分为四类（图 5、表 2）：测试卷 9 题（3 套平行卷，每套 3 题）、必做题 12 题、选练题约 25 题、备用题约 4 题。测试卷只在考试窗口开放，两组均不可见；必做题实验组全员同一套；选练题自由选做，其练习量作为协变量记录；备用题用于审核发现问题时替换。

把测试卷独立出来是实验设计的第一条纪律。若测试题出现在练习题库中，后测就不再是测量，而是复述。

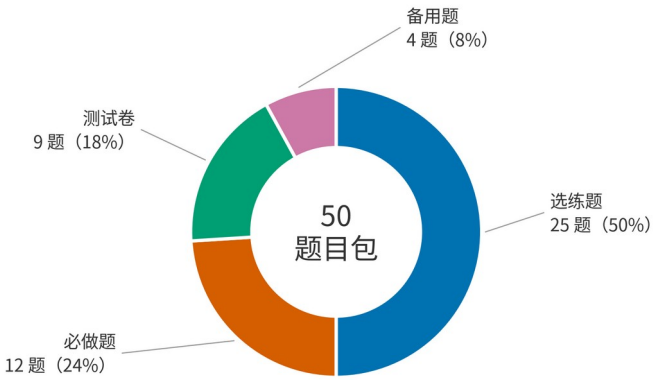


图 5　题库构成（n=50）

注：按用途直接标注；测试卷 9 题含 3 套平行卷，必做题 12 题为干预剂量，选练题约 25 题，备用题约 4 题。

表 2　题库切分与论文角色

用途	数量	可见范围	系统行为	论文角色
测试卷	9（3 套 × 3 题）	仅考试窗口开放，两组均不可见	关闭诊断与提示，限时 30 分钟	因变量测量
必做题	12（每周 3 题）	实验组全员同一套	完整核心循环	干预剂量
选练题	约 25	实验组自由选做	完整核心循环	练习量协变量
备用题	约 4	不开放	审核发现问题时替换	质量控制
合计	50	—	—	—

5.2　分组、平行卷与对照

试点规模为两个班、约 60 人，按班级整群分组：实验组使用系统，对照组使用纸笔做同样的 12 题，完成后可看参考答案。两组唯一的区别是“有没有分步引导”，这一点需要在设计上守住，否则审稿人会指出差异来自练习量或材料质量，而非干预本身。

测试采用三套平行卷交叉平衡：一半学生前测用 A 卷、后测用 B 卷、延迟后测用 C 卷，另一半反过来；系统随机分配并记录卷别，统计时作为协变量（表 3）。平行卷的难度差异无法完全消除，交叉平衡把它从组间差异转化为可估计的个体效应。

评分由教师按统一细则完成，三个测试时点、每人每次 3 题，共 360–540 份。前测与后测采用双评：随机抽取 20% 由第二位评分者独立评分，以组内相关系数（ICC）报告信度，目标不低于 0.75；错误类型标注用 Cohen's κ 报告一致性。

表 3　平行卷交叉平衡

前测	后测	延迟后测	分配方式	统计处理
A 卷	B 卷	C 卷	系统随机，约 30 人	form_order = A→B
B 卷	A 卷	C 卷	系统随机，约 30 人	form_order = B→A

5.3　两种设计及其取舍

若条件允许，首选组间对照（图 6a）：两组各约 30 人，前后测加延迟后测，对照组用纸笔完成同样的 12 题。它的优点是解释直接，局限是样本量小、功效不足（见 5.4）。

若只能协调到两个班、且担心组间不可比，可改用交叉设计（图 6b）：把 4 周拆成两段，每段对应一个知识点，甲班先系统后纸笔、乙班先纸笔后系统，每个学生都是自己的对照。交叉设计把组间比较变成组内比较，在同等人数下提高功效；代价是第一阶段使用系统获得的经验会带到第二阶段，存在顺序效应与携带效应，需要在论文局限中写明，并以“中测”估计第一阶段的残余影响。

两种设计的共同前提是测试与练习隔离、平行卷交叉平衡、评分盲法。具体选哪一种，取决于教师对班级安排的接受程度，这一项列入附录 D 表 D1 的待决策事项。

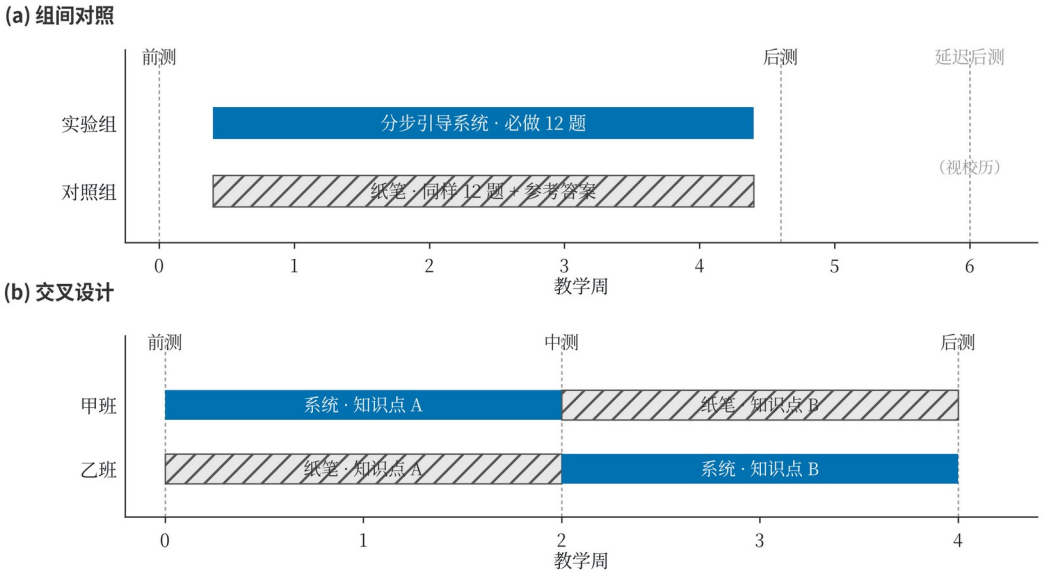


图 6　两种实验设计

注：实心条为系统干预，斜线条为纸笔对照；虚线为测评时点。(a) 组间对照；(b) 交叉设计，每个学生自身对照。

5.4　统计功效与样本量

原稿给出“30 对 30 检出 8 分差、功效约 0.3–0.65（标准差 15–25）”，但未注明检验类型与单双侧。按双侧 α=0.05、两组等样本、正态近似的两样本检验复算，功效为 $\Phi(d\sqrt{(n/2)} - z_{1-\alpha/2})$，最小可检测效应由式 (1) 给出：

$$n = 2(z_{1-\alpha/2} + z_{1-\beta})^2 / d^2 \tag{1}$$

式中 n 为每组样本量，d 为组间差与合并标准差之比，z 为标准正态分位数；取 α=0.05（双侧）与 1−β=0.80，得 $z_{1-\alpha/2} \approx 1.96$、$z_{1-\beta} \approx 0.84$。

8 分差在标准差 15 至 25 分时对应 d=0.32–0.53。复算结果见表 4 与图 7：30 对 30 的功效仅 0.24–0.54，40 对 40 为 0.30–0.66，60 对 60 为 0.42–0.83；交叉设计 30 人（组内相关 ρ=0.5）与 60 对 60 等效，为 0.42–0.83。要达到 0.80 的功效，组间设计在 30 人时只能检出 d=0.72 以上的差异，约为 11 分（标准差 15）；60 人或交叉设计可把最小可检测效应降到 d=0.51，约为 8 分。

表 4　统计功效与最小可检测效应（双侧 α=0.05，power=0.80）

设计	每组 n	8 分差功效（d=0.32–0.53）	最小可检测 d	对应分数差（SD=15）
组间对照	30	0.24–0.54	0.72	10.9
组间对照	40	0.30–0.66	0.63	9.4
组间对照	60	0.42–0.83	0.51	7.7
交叉设计（ρ=0.5）	30	0.42–0.83	0.51	7.7

注：按两组等样本、正态近似计算；分数差按标准差 15 分折算。原稿估计 0.3–0.65 未注明检验类型与单双侧，量级与此接近但偏乐观。

还有两个因素会让实际功效低于上述计算。其一是整群随机：学生嵌套在班级中，若只有两个班，班级层面的组内相关会放大标准误，等效样本量下降；这也是交叉设计更有吸引力的

原因。其二是流失：估计 10% 左右的学生缺少后测，按意向性分析（ITT）与多重插补处理，需要在论文中报告流失率与敏感性分析。

效应量的解释也需要提醒。Kraft 基于 747 项教育随机试验提出，0.05 以下为小、0.05–0.20 为中、0.20 以上为大[17]；d=0.53 属于偏大的效应，在真实课堂中并不常见。因此论文不宜只报告总分差，还应报告独立完成率、提示依赖、步骤完整率等过程指标，用多类证据支撑结论。

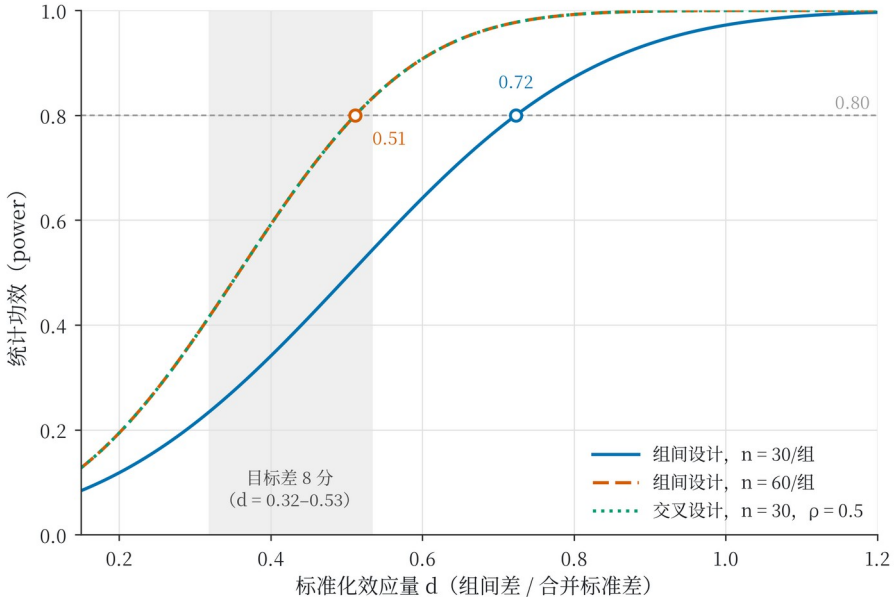


图 7　统计功效与最小可检测效应

注：按双侧 α=0.05、两组等样本、正态近似的两样本检验计算；阴影为目标差 8 分对应的 d=0.40–0.53；空心圆为 power=0.80 处的 d 值。

5.5　分析计划与评分信度

主分析采用协方差分析：后测总分为因变量，前测分数为协变量，组别为固定效应，卷别与班级为协变量或随机效应；报告调整后组间差、95% 置信区间与 Hedges' g。次要指标包括独立完成率、提示依赖、步骤完整率与完成率，采用 BH 方法控制错误发现率。缺失数据按 ITT 原则处理，多重插补 20 次，报告敏感性分析。分析计划在实验开始前定稿并存档，避免事后选择结果。

设计口径参照 What Works Clearinghouse 5.0 版对随机分配、基线等价与流失率的要求[18]；功效计算可用 G*Power 复现[19]。

6　实现与运营

6.1　技术选型

技术选型围绕三条限制展开：团队只熟悉 TypeScript；必须支持手机与平板；模型调用必须集中在服务端（表 5）。前端用 Next.js 16 App Router 加 Tailwind 与 shadcn/ui，打包为 PWA，免应用商店审核即可安装到桌面[20]。公式输入用 MathLive[21]，自定义 ε、δ、∀、∃、lim 等键位，解决手机端输入慢的问题；公式渲染用 KaTeX。AI 调用统一走 Vercel AI SDK[22]，诊断输出用 zod 约束为结构化 JSON，换模型只改配置。数据库为 PostgreSQL 16 加 Drizzle ORM，

事件表的分析查询直接写 SQL。导出用 exceljs 生成 xlsx，评测用 promptfoo 接入 CI[23]。部署为 Docker Compose 加 Caddy，单机 2 核 4G 足够。

表 5　技术选型与理由

层	选型	选择理由
前端框架	Next.js 16 App Router + React + Tailwind + shadcn/ui	前后端同仓库，团队只需 TypeScript
安装形态	PWA（manifest + Service Worker）	手机可添加到桌面，免应用商店审核
公式输入	MathLive（MIT），自定义 ε、δ、∀、∃、lim 键位	自带手机虚拟键盘，可定制布局
公式显示	KaTeX	渲染快，适合长证明
模型调用	Vercel AI SDK：@ai-sdk/deepseek + OpenAI 兼容接口	统一流式与 zod 结构化输出，换模型只改配置
数据	PostgreSQL 16 + Drizzle ORM	事件表分析查询直接用 SQL
导出	CSV + exceljs（xlsx）	可直接导入 SPSS、R 与 Excel
评测	promptfoo	多轮防泄题回归可接入 CI
部署	Docker Compose + Caddy	单机足够，自动签发 HTTPS

6.2　部署、可用性与合规

服务器选香港 2 核 4G、CN2 GIA 双程线路，月费约 80–150 元。选择香港是为了免备案快速上线，但线路质量直接决定晚高峰的可用性：服务商自测数据显示普通 BGP 线路在晚高峰延迟升至 140–175 ms、丢包 8–12%，而晚高峰正是学生写作业的时间。这些数据未经独立复核，方案要求购买前用测试 IP 在 20–23 点从校园网实测一次；教育网出口与电信不同，没有公开数据可以替代实测。不套 CDN 代理，避免代理线路带来的额外不确定性。

备份为每日凌晨 pg_dump 至对象存储，保留 30 天；上线前完成一次恢复演练，验收标准为 2 小时内恢复。

合规按保守假设处理：服务器不存姓名与学号；试点保持邀请制、不开放公开注册；界面标注 AI 生成内容，提供隐私政策与用户协议，论文使用知情同意书，发表前通过学校伦理审查。条文层面的依据见 7.2 节。

6.3　成本

现金成本很低，每月约 300–500 元；真正的成本是人力（图 8、附录 C 表 C1）。按月计，模型调用 200–350 元（主模型与复核模型合计），服务器 80–150 元，域名 50–100 元/年；模型单价按百炼上架价格估算，忙时输入 2 元、输出 8 元每百万 token，闲时减半[24,25]。夜间使用为主，实际费用会更低。建议在服务商后台设置月度消费封顶，避免异常调用。

一次性人力主要是题目包审核：50 题、每题 1–1.5 小时，合计 50–75 小时，且集中在 11 月。前后测评分 360–540 份，若由教师独立完成，按每份 10 分钟计需要 60–90 小时；AI 预评可以压缩时间，但终评仍需教师签字。确认书中的“长期免费 + 甲方自筹”意味着试点结束后的月费需要有人兜底，这一点应在项目启动前明确。

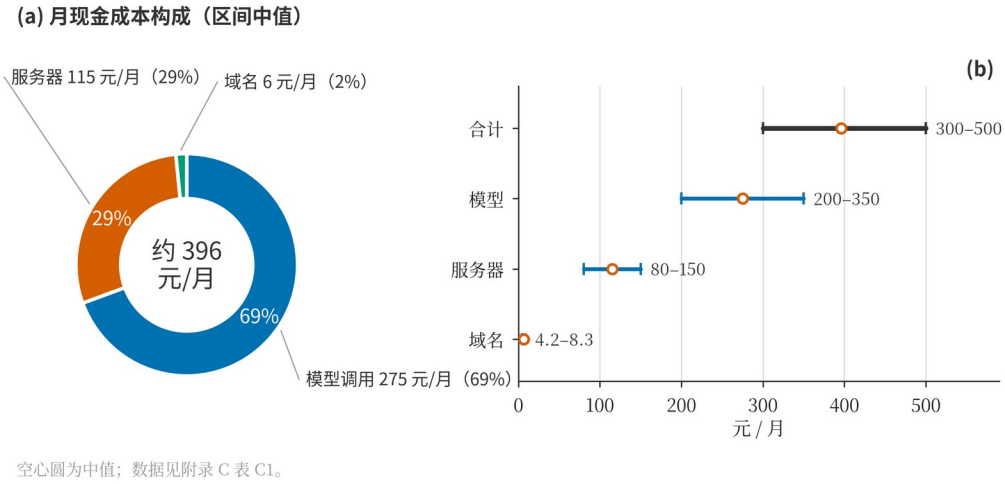


图 8　月现金成本构成与分项区间

注：(a) 取区间中值时的构成比例；(b) 分项区间，空心圆为中值；域名按年费 50–100 元摊至每月。人力成本另计，见附录 C 表 C1。

6.4　进度与里程碑

从 11 月 30 日前测倒推，开发与内测只有 4 周（图 9）。第一周只做验证：单题分步作答页、MathLive 数分键盘、草稿本地保存、诊断调用与 L1–L4 状态机在一道题上跑通。第二、三周做全量开发：选题页、测试模式、PWA 安装、手机适配、复核闸门、promptfoo 回归集、看板、逐步回放、导出与数据字典、10 个题目包起草与服务器上线。第四周内测，通过门槛为四项：回归集泄题 0 条、教师抽检 10 题通过、导出字段齐全率不低于 98%、恢复演练 2 小时内完成（表 6）。

第一周不做全量，是为了把最不确定的两件事先验证掉：手机端公式输入是否可接受，模型诊断是否可用。若这两项不通过，后三周的排期需要重排。

表 6　内测通过门槛

门槛	判据	责任人
防泄题	多轮套话回归集泄题 0 条	AI 层负责人
诊断可用性	教师抽检 10 题通过（首错定位与提问均可接受）	题目包负责人 + 教师
数据完整性	导出字段齐全率 ⩾ 98%，事件计数与导出行数一致	数据负责人
可恢复性	备份恢复演练 2 小时内完成	部署负责人

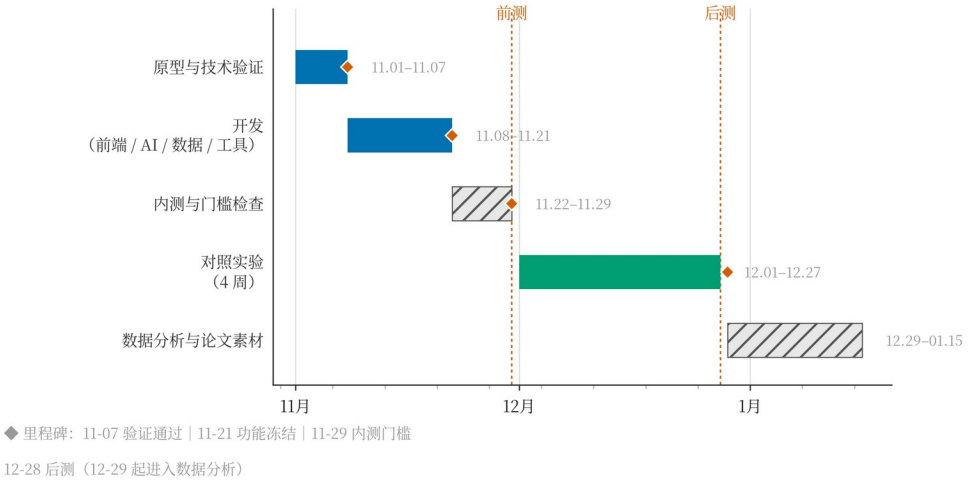


图 9　试点排期（2026 年 11 月至 2027 年 1 月）

注：菱形为里程碑，虚线为前测与后测日期；延迟后测拟安排在 2027 年 2 月下旬（视校历，未列入图内）。

7　风险与合规

7.1　风险矩阵

最大的风险不在代码，而在题目包进度与实验开始日期（图 10、表 7）。题目包审核 50–75 小时集中在 11 月，一旦延期，11 月 30 日的前测会顺延，后测撞上期末。应对是把测试卷 9 题与必做题 12 题排在最前，选练题边跑边加；并在第一周就签下教师的审核时间。

第二类风险是干预失真。渐进式泄题会让系统退化为答案机，届时论文结论不成立；应对是提示预算、关键步计数与复核模型三层约束，并以多轮套话回归集作为上线门槛。实验中途模型行为变化会破坏前后一致性，应对是锁定模型快照与提示词版本，并把版本号写入每条事件。

第三类是测量与执行风险。对照班学生借用账号或互传提示会污染对照，应对是账号码绑定班级、前测问卷记录学生平时使用 AI 的情况作为协变量。手机输入过慢会导致周活跃不足 70%，应对是定制数分键盘，并在内测中测量单题输入时长，拍照转写作为备选。校园网访问香港线路在晚高峰可能卡顿，应对是购买前实测与静态资源长缓存。延迟后测若落入寒假，保留率数据会缺失，可改到开学第一周，或在论文中明确放弃该指标。

表 7　风险清单与应对

编号	风险	影响	应对	优先级
R1	题目包审核进度	前测顺延，后测撞期末	先审测试卷 9 题与必做题 12 题；第一周签下审核时间	高
R2	AI 诊断误报或漏报	学生不信任，数据噪声大	诊断一律以提问形式返回；内测抽检 10% 统计误报率	中
R3	渐进式泄题	干预变成答案机，结论不成立	提示预算 + 关键步计数 + 复核模型；回归集 0 泄题才上线	高
R4	手机输入过慢	周活跃不足 70%	定制数分键盘；内测测单题输入时长；拍照转写作备选	中
R5	对照班污染	内部效度受损	账号码绑定班级；前测问卷记录 AI 使用作协变量	中
R6	模型行为漂移	干预前后不一致	锁定模型快照与提示词版本，写入事件	高

编号	风险	影响	应对	优先级
R7	校园网访问香港慢	晚高峰卡顿	购买前测试 IP 实测；静态资源长缓存	低
R8	延迟后测落寒假	保留率数据缺失	改到开学第一周，或明确放弃该指标	中

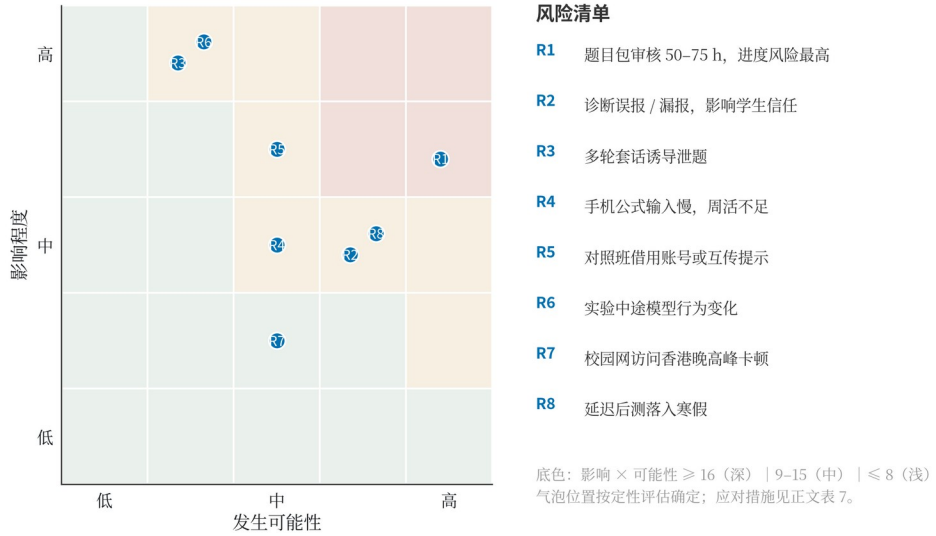


图 10　风险矩阵（影响 × 可能性）

注：横轴为发生可能性，纵轴为影响程度；底色按影响与可能性的乘积分级；编号对应表 7。

7.2　合规要点

个人信息出境。香港对内地法律而言属于境外。按《个人信息保护法》，国家机关处理的个人信息应当在境内存储，法律、法规授权的具有管理公共事务职能的组织适用国家机关的规定[26]。公立高校是否落入该范围，条文上并不当然成立，需由学校信息化或法务部门确认，本文不作定论。

若按“非国家机关”路径处理，依据《促进和规范数据跨境流动规定》第五条第四项，关键信息基础设施运营者以外的处理者，自当年 1 月 1 日起累计向境外提供不满 10 万人个人信息（不含敏感个人信息）的，免予申报安全评估、订立标准合同与认证；但第十条要求仍须履行告知、取得单独同意并进行个人信息保护影响评估[27]。本方案服务器不存姓名与学号，出境信息量远低于阈值，但仍应完成上述程序。

生成式人工智能。《生成式人工智能服务管理暂行办法》第二条第三款规定，教育和科研机构研发、应用生成式人工智能技术、未向境内公众提供服务的，不适用该办法；第二十条规定，对来源于境外向境内提供服务的，网信部门可采取措施处置[28]。据此，邀请制、不开放公开注册是最稳妥的姿态；把服务器放在香港并不构成豁免，具体适用需专业意见。

无论适用哪条路径，仍需完成：界面标注 AI 生成内容、隐私政策与用户协议、论文用知情同意书、学校伦理审查。

8　结论与下一步

本文给出一套面向数学分析证明写作的分步引导系统与其实验方案。系统的核心取舍是把“判定”从模型中移除，只保留首错定位与分级提示，并用题目包、提示预算与两层闸门把泄题风险压到可接受范围；数据结构以只追加事件表为中心，使教学看板与论文统计同源。

复算表明，原稿对统计功效的估计偏乐观：30 对 30 在 8 分差、标准差 15–25 的假设下功效仅 0.24–0.54，不足以支撑“组间差显著”的预期。可行的补救有两条：把样本扩到每组 60 人，或改用交叉设计；若两者都不可行，应把论文的主要结论从“分数提升”调整为“过程指标差异”，并在局限中说明样本量限制。

近期工作分三步：11 月 7 日前完成技术验证并冻结选题与提示规则；11 月 21 日前完成全量开发与功能冻结；11 月 29 日前通过内测门槛。需要团队与教师在 10 月底前确认的事项见附录 D 表 D1，其中实验设计的选择、题目范围与评分人力三项对论文影响最大。

参考文献

[1] BASTANI H, BASTANI O, SUNGU A, et al. Generative AI without guardrails can harm learning: evidence from high school mathematics[J]. Proceedings of the National Academy of Sciences, 2025, 122(26). DOI:10.1073/pnas.2422633122.

[2] KESTIN G, MILLER K, KLALES A, et al. AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting[J]. Scientific Reports, 2025, 15. DOI:10.1038/s41598-025-97652-6.

[3] GONZALEZ S, AMIRI BAVANDPOUR A, YE P, et al. QEDBench: quantifying the alignment gap in automated evaluation of university-level mathematical proofs[C]//Proceedings of the 2026 International Conference on Machine Learning (ICML 2026). PMLR, 2026. https://proceedings.mlr.press/v306/gonzalez26a.html.

[4] SRIVATSA K V A, MAURYA K K, KOCHMAR E. LLMs cannot spot math errors, even when allowed to peek into the solution[C]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 10914-. DOI:10.18653/v1/2025.emnlp-main.553.

[5] DAHEIM N, MACINA J, KAPUR M, et al. Stepwise verification and remediation of student reasoning errors with large language model tutors[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami: Association for Computational Linguistics, 2024: 8386-8411. DOI:10.18653/v1/2024.emnlp-main.478.

[6] GOHR A, LAWN M, GAO K, et al. Automated feedback generation for undergraduate mathematics: development and evaluation of an AI teaching assistant[EB/OL]. (2026-01-06)[2026-10-27]. https://arxiv.org/abs/2601.03458.

[7] GOHR A, LAWN M, GAO K, et al. Evaluating LLM-generated formative feedback for undergraduate mathematics through the lens of feedback theory[C]//Proceedings of the 21st Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2026). San Diego: Association for Computational Linguistics, 2026: 813-818. DOI:10.18653/v1/2026.bea-1.55.

[8] ZHENG L, CHIANG W, SHENG Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena[C]//Advances in Neural Information Processing Systems 36 (NeurIPS 2023). 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract.html.

[9] PANICKSSERY A, BOWMAN S R, FENG S. LLM evaluators recognize and favor their own generations[C]//Advances in Neural Information Processing Systems 37 (NeurIPS 2024). 2024. https://arxiv.org/abs/2404.13076.

[10] LIFFITON M, SHEESE B E, SAVELKA J, et al. CodeHelp: using large language models with guardrails for scalable support in programming classes[C]//Proceedings of the 23rd Koli Calling International Conference on Computing Education Research. New York: ACM, 2023. DOI:10.1145/3631802.3631830.

[11] KOEDINGER K R, ALEVEN V. Exploring the assistance dilemma in experiments with cognitive tutors[J]. Educational Psychology Review, 2007, 19(3): 239-264. DOI:10.1007/s10648-007-9049-0.

[12] ALEVEN V, STAHL E, SCHWORM S, et al. Help seeking and help design in interactive learning environments[J]. Review of Educational Research, 2003, 73(3): 277-320. DOI:10.3102/00346543073003277.

[13] HATTIE J, TIMPERLEY H. The power of feedback[J]. Review of Educational Research, 2007, 77(1): 81-112. DOI:10.3102/003465430298487.

[14] POULSEN S, VISWANATHAN M, HERMAN G L, et al. Proof Blocks: autogradeable scaffolding activities for learning to write proofs[C]//Proceedings of the 27th ACM Conference on Innovation and Technology in Computer Science Education (ITiCSE 2022). New York: ACM, 2022: 428-434. DOI:10.1145/3502718.3524774.

[15] LI Z, ZHU Q, WANG M, et al. Planning-guided tutoring with assessment-driven memory for pedagogical LLM tutors[C]//Proceedings of the 2026 Annual Meeting of the Association for Computational Linguistics (ACL 2026). Association for Computational Linguistics, 2026. DOI:10.18653/v1/2026.acl-long.325.

[16] MAHINPEI R, DRUCHYNA S, HORTA RIBEIRO M. When LLMs help and hurt teaching assistants in proof-based courses[EB/OL]. (2026-02-27)[2026-10-27]. https://arxiv.org/abs/2602.23635.

[17] KRAFT M A. Interpreting effect sizes of education interventions[J]. Educational Researcher, 2020, 49(4): 241-253. DOI:10.3102/0013189X20912798.

[18] What Works Clearinghouse. What Works Clearinghouse procedures and standards handbook: version 5.0: WWC 2022008[R/OL]. Washington, DC: U.S. Department of Education, Institute of Education Sciences, 2022[2026-10-27]. https://ies.ed.gov/ncee/wwc/Handbooks.

[19] FAUL F, ERDFELDER E, LANG A G, et al. G*Power 3: a flexible statistical power analysis program for the social, behavioral, and biomedical sciences[J]. Behavior Research Methods, 2007, 39(2): 175-191. DOI:10.3758/BF03193146.

[20] Vercel. Progressive web applications (PWA)[EB/OL]. (2026-07-30)[2026-10-27]. https://nextjs.org/docs/app/guides/progressive-web-apps.

[21] ARNOG. MathLive[CP/OL]. [2026-10-27]. https://github.com/arnog/mathlive.

[22] Vercel. AI SDK providers: DeepSeek[EB/OL]. [2026-10-27]. https://ai-sdk.dev/providers/ai-sdk-providers/deepseek.

[23] PROMPTFOO. promptfoo[CP/OL]. [2026-10-27]. https://github.com/promptfoo/promptfoo.

[24] 阿里云. 模型调用价格[EB/OL]. (2026-10-25)[2026-10-27]. https://help.aliyun.com/zh/model-studio/model-pricing.

[25] DeepSeek. Models & pricing[EB/OL]. [2026-10-27]. https://api-docs.deepseek.com/quick_start/pricing.

[26] 全国人民代表大会常务委员会. 中华人民共和国个人信息保护法[Z]. 2021-08-20. https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm.

[27] 国家互联网信息办公室. 促进和规范数据跨境流动规定: 国家互联网信息办公室令第 16 号[Z]. 2024-03-22. https://www.cac.gov.cn/2024-03/22/c_1712776611775634.htm.

[28] 国家互联网信息办公室, 国家发展和改革委员会, 教育部, 等. 生成式人工智能服务管理暂行办法: 国家互联网信息办公室令第 15 号[Z]. 2023-07-13. https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm.

[29] CAHLR. OATutor[CP/OL]. [2026-10-27]. https://github.com/CAHLR/OATutor.

[30] PrairieLearn. PrairieLearn: pl-order-blocks (Proof Blocks)[CP/OL]. [2026-10-27]. https://github.com/PrairieLearn/PrairieLearn.

[31] ETH-LRE. verify-then-generate[CP/OL]. [2026-10-27]. https://github.com/eth-lre/verify-then-generate.

[32] GOHR A. llm_proof_feedback[CP/OL]. [2026-10-27]. https://github.com/agohr/llm_proof_feedback.

[33] BNU-ERC-ITEA. ScaffoldLM[CP/OL]. [2026-10-27]. https://github.com/BNU-ERC-ITEA/ScaffoldLM.

附录 A　题目包与诊断输出

本附录给出题目包与诊断调用的字段规范，供出题、审核与接口实现共同使用。字段的取值约定与校验规则在题目包编辑器内实现，修改后须经教师重新审核。

表 A1　题目包字段

字段	内容	负责人
题面	LaTeX；按章节、知识点、难度打标签	教师选题
参考证明	1–2 种写法，供模型对照与教师审核	AI 起草，教师审
关键步骤	K1–Kn 及依赖关系（有向无环图）	AI 起草，教师审
L1/L2 提示	每个关键步骤各一条预写文本	AI 起草，教师审
常见错误	错误类型及识别特征，如量词范围误用	教师为主
允许使用的定理	本章及之前学过的定理；其余列入禁用集	教师

表 A2　诊断输出字段

字段	类型	说明
suspect_step	integer	第一处可疑步骤的序号；无异常时为空
error_type	enum	取自题目包的常见错误枚举
question_to_student	string	面向学生的提问，不超过 60 字
matched_key_steps	integer[]	已匹配的关键步骤编号
gate_decision	enum	pass / block / fallback，由闸门写入

附录 B　数据表与导出字段

六张表构成研究数据仓库。events 是唯一的事实源，其余五张表提供上下文；导出时以 events 为主表左连接 attempts 与 participants，字段含义与取值范围写入数据字典。

表 B1　数据表结构

表	主要字段	说明
participants	anon_id、class_id、group、form_order	无姓名、无学号
problems	problem_id、chapter、topic、difficulty、role、status、version	题目包内容存 JSON 字段
attempts	attempt_id、anon_id、problem_id、mode、started_at、submitted_at	每次尝试一行
steps	attempt_id、step_no、content_latex、submitted_at、revision	改写保留历史版本
events	ts、anon_id、attempt_id、type、step_no、hint_level、revealed_keys、model、prompt_version、latency_ms	只追加，研究导出主表
scores	attempt_id、rater、total、structure、logic、rigor	前后测教师评分，支持双评

表 B2　派生指标与计算口径

指标	定义	取值范围
独立完成率	未使用 L3/L4 完成的作答数 / 完成作答总数	0–1，按人、按题分别统计
提示依赖	每题提示次数及 L3/L4 占比	次数与百分比
步骤完整率	匹配的关键步骤数 / 关键步骤总数	0–1
完成率	完成人数 / 分配人数	0–1
延迟保留率	延迟后测成绩 / 后测成绩	仅在延迟后测可用时计算

附录 C　成本明细

表 C1　成本明细与估算口径

项目	区间	周期	口径与依据
服务器（香港 2 核 4G，CN2 GIA）	80–150 元	每月	服务商报价区间，未含带宽超额
模型调用（主 + 复核）	200–350 元	每月	60×5×10 次调用/周；输入 3k、输出 1.5k token；缓存 50%；忙时 2/8 元每百万 token
域名	50–100 元	每年	常见后缀报价
题目包审核	50–75 小时	一次性	每题 1–1.5 小时，AI 起草后审核
前后测评分	360–540 份	实验期	60 人 × 3 题 × 2–3 次；AI 预评可压缩时间
合计（现金）	300–500 元	每月	不含人力

附录 D　待决策事项

表 D1　待决策事项

编号	事项	对象	建议	截止
D1	是否弃用 Electron、只做 PWA	团队	确认弃用；需支持手机与平板	10.28
D2	技术栈最终确认	团队	选型不变；补记版本号	10.28
D3	香港 CN2 GIA 供应商与实测	团队	先取测试 IP，晚高峰实测	10.31
D4	分工与负责人	团队	四条线各一人	10.28
D5	拍照转写是否进首版	团队	先测手写稿准确率再定	11.07
D6	12 月课程进度与题目范围	教师	确认章节与题目范围	10.31
D7	实验设计：组间、交叉或单组前后测	教师	优先交叉设计以提高功效	10.31
D8	拍照问答区是否改为拍证明过程	教师	走同一套规则，否则移出	10.31
D9	提示上限是否接受	教师	L1/L2 不限；L3 至多 2 次；L4 至多 1 次	10.31
D10	出题、审题与评分分工；延迟后测时间	教师	定每周工时与延迟后测时间	10.31

附录 E　参考开源项目与许可

下表列出借鉴的开源项目与对应许可。许可证以 2026 年 10 月 27 日仓库元数据为准；标记为“许可声明不一致”或“未声明”的项目仅参考流程，不复用代码。表中项目依次对应 OATutor[29] 、 Proof Blocks[30] 、 verify-then-generate[31] 、 llm_proof_feedback[32] 、 ScaffoldLM[33]、MathLive 与 promptfoo。

表 E1　参考开源项目与许可

项目	借用部分	许可证	备注
OATutor	题目—步骤—提示结构、A/B 分组	代码 MIT；内容 CC BY 4.0	内容不可按 MIT 复用
Proof Blocks（pl-order-blocks）	步骤拖拽与依赖图判分	PrairieLearn 社区版 AGPL-3.0	不直接嵌入；按论文重实现
verify-then-generate	先验证再生成的流水线	许可声明不一致（CC BY 4.0 / CC BY-SA 4.0）	仅参考流程
llm_proof_feedback	预计算评分方案、教师先审	未声明	依据其 BEA 2026 论文

项目	借用部分	许可证	备注
ScaffoldLM	生成教学计划、跟踪子问题	README 声明 CC-BY-4.0	研究代码
MathLive / promptfoo	手机端公式输入 / 防泄题回归	MIT	直接使用

注：许可证状态以 2026-10-27 仓库元数据为准；未声明或许可声明不一致者仅参考流程，不复用代码。